

Agent Bot จะเปลี่ยนห่วงโซ่มูลค่า AI อย่างไร

ชุดอ่าน 01 — พื้นฐานและภาพรวม

ขอบเขตที่เจ้าของงานเลือก: ห่วงโซ่มูลค่า AI ทั้งระบบ พร้อมเจาะโครงสร้างพื้นฐาน (ชิป คลาวด์ ดาต้า เซ็นเตอร์ เครือข่าย และพลังงาน)

ผู้อ่าน: ผู้สนใจเทคโนโลยี ธุรกิจ และการลงทุนที่ต้องการเข้าใจกลไกก่อนประเมินผู้ได้ประโยชน์

ตรวจหลักฐานถึง: 29 กันยายน 2026

สถานะ: เอกสารเพื่ออ่านและอภิปราย ยังไม่ได้เลือกข้อสรุปหลักสำหรับเรื่องเล่า

คำตอบสั้นสำหรับตั้งต้น

Agent Bot คือระบบ AI ที่รับเป้าหมาย ใช้เครื่องมือลงมือหลายชั้น ตรวจผล และขอความช่วยเหลือเมื่อจำเป็น การแข่งขันนี้อาจเพิ่มจำนวนงานที่ส่งให้ AI ทำ และเพิ่มความต้องการระบบประมวลผลระหว่างใช้งาน หรือ **inference** แต่ผลต่อยอดขายชิปและกำไรของผู้เล่นแต่ละชั้นไม่ได้โตตามจำนวน Agent โดยตรง ต้นทุนต่อหนึ่งงานกำลังลดลง งานจำนวนหนึ่งยังต้อง

ใช้คนตรวจ และการขยายดาต้าเซ็นเตอร์ติดข้อจำกัด
ด้านหน่วยความจำ ไฟฟ้า และเงินทุน [Anthropic:](#)
[นิยาม Agent](#) · [IEA: พลังงานและ AI](#)

ข้อเท็จจริง: หลายบริษัทเปิดผลิตภัณฑ์ Agent ที่มี
รูปแบบต่างกันจริง

ข้อวิเคราะห์: บริษัทที่ครองจุดรับงาน ข้อมูล สิทธิ
และการตรวจผล อาจรักษาความสัมพันธ์กับลูกค้าได้
แม้เปลี่ยนโมเดลหรือชิปเบื้องหลัง

สิ่งที่ยังไม่รู้: รายได้ กำไร และปริมาณการประมวล
ผลที่เกิดจาก Agent โดยเฉพาะในระดับอุตสาหกรรม
ยังวัดแยกได้ไม่ดี

1. Agent ต่างจากแชทบอตอย่างไร

แชทบอตมักตอบคำถามหรือสร้างรายงาน ส่วน Agent
ทำงานเป็นวงจร: **รับเป้าหมาย → วางขั้นตอน →**
เรียกเครื่องมือ → ดูผล → แก้มหรือส่งให้คนตรวจ
ตัวอย่างเช่น อ่านใบแจ้งปัญหา เปิดระบบงาน หา
เอกสารที่เกี่ยวข้อง แก้มข้อมูลในระบบ และรายงานว่า
ทำสำเร็จหรือพบข้อยกเว้น Anthropic อธิบายว่า
Agent มีสี่ส่วน: โมเดล, ชุดกติกาและตัวควบคุมการ
ทำงาน (harness), เครื่องมือ, และสภาพแวดล้อมที่
รันงาน [Anthropic, 9 เม.ย. 2026](#)

“Agent Bot” ไม่ใช่มาตรฐานเดียวกันทุกบริษัท บางรายขายบอดสำเร็จรูปให้พนักงาน บางรายขาย API ให้ผู้พัฒนาสร้าง Agent เอง และบางรายขายระบบควบคุมสิทธิ์/ติดตาม Agent ในองค์กร จึงไม่ควรนับทุกการประกาศเป็นผลิตภัณฑ์ชนิดเดียวกัน

2. บริษัทกำลังสร้างอะไรจริง

- **Anthropic:** Claude Code และ Cowork เป็นตัวอย่างการมอบหมายงานหลายขั้นให้ระบบทำ ข้อมูลการใช้งานของ Anthropic พบว่า session แบบ Agent ที่ทำงานยาวขึ้นมีบทบาทมากขึ้น แต่ข้อมูลนี้ครอบคลุมผลิตภัณฑ์ของ Anthropic ไม่ใช่ทั้งหมด [Economic Index, 26 มิ.ย. 2026](#)
- **Google:** Managed Agents ใน Gemini API ให้ Agent ใช้เครื่องมือและรันโค้ดในสภาพแวดล้อมแยก ส่วน TPU 8i ถูกออกแบบเพื่อ inference ที่ต้องตอบเร็ว ทั้งสองอย่างแสดงการเชื่อมผลิตภัณฑ์ Agent เข้ากับโครงสร้างพื้นฐานของตน [Managed Agents, 19 พ.ค. 2026](#) · [TPU 8i, 22 เม.ย. 2026](#)

- **AWS:** AgentCore เสนอ runtime, การเชื่อมต่อเครื่องมือ, สิทธิ, การสังเกตการทำงาน และการประเมินผล โดยรองรับหลายโมเดล แสดงว่าคลาวด์สามารถขยายขั้นปฏิบัติการของ Agent โดยไม่จำเป็นต้องผูกกับโมเดลเดียว [AWS AgentCore, 22 เม.ย. 2026](#) · [คู่มือ AWS](#)
- **Microsoft:** Agent 365 วางตัวเป็นศูนย์กลางและกำกับ Agent ในองค์กร นอกเหนือจาก Copilot ที่ผู้ใช้เห็นโดยตรง [Microsoft, 9 มี.ค. 2026](#)
- **OpenAI:** Agents API ที่เปิด public beta วันที่ 10 ก.ย. 2026 ให้ผู้พัฒนาใช้ harness และสภาพแวดล้อมสำหรับงานยาว คิดค่าบริการตามโมเดล เครื่องมือ และ sandbox ที่ใช้ ไม่คิดค่าธรรมเนียม API เพิ่มสำหรับตัว Agent เอง [OpenAI, 10 ก.ย. 2026](#) · [คู่มือราคา](#)
- **SpaceXAI:** Grok Bot beta เป็นบอตที่มีคอมพิวเตอร์บนคลาวด์และทำงานข้ามแอป เป็นอีกทางเข้าตลาดแบบผลิตภัณฑ์สำเร็จรูป ข้อความเกี่ยวกับความสามารถและประสิทธิภาพเป็นคำอธิบายจากผู้ขาย [SpaceXAI, 11 ส.ค. 2026](#)

การเปิดตัวเหล่านี้ยืนยัน **การแข่งขันด้านผลิตภัณฑ์ และแพลตฟอร์ม** แต่ยังไม่พิสูจน์ว่า Agent ทุกชนิดมีผลตอบแทนสุทธิ หรือบริษัทใดจะเป็นผู้ชนะถาวร

3. แผนที่ห่วงโซ่มูลค่า

มองจากสิ่งที่ผู้ใช้สัมผัสลงไปถึงสิ่งที่ต้องสร้างทางกายภาพ:

- แอปและทางเข้างาน:** บอตในแชต แอปสำนักงาน เครื่องมือเขียนโค้ด และระบบงานเฉพาะอุตสาหกรรม ผู้ครองจุดนี้เห็นโจทย์ของผู้ใช้และออกแบบประสบการณ์อันมีติงาน
- ข้อมูล สิทธิ และเครื่องมือ:** ตัวเชื่อมกับไฟล์อีเมล ERP/CRM และ API พร้อมการยืนยันตัวตน บันทึกการกระทำ และกติกากว่า Agent ทำอะไรได้
- Harness และบริการรัน Agent:** เก็บบริบท วางรอบการทำงาน จัดการความล้มเหลว sandbox และการประเมินผล ขั้นนี้เป็นต้นทุนและแหล่งรายได้ใหม่ของผู้ใช้บริการแพลตฟอร์ม
- โมเดลและ inference:** Agent อาจเรียกโมเดลหลายครั้ง ใช้โมเดลต่างขนาดสำหรับขั้นง่าย/ยาก และเรียกเครื่องมือระหว่างทาง

5. คลาวด์และเครื่องประมวลผล: เซิร์ฟเวอร์

GPU/ASIC หน่วยความจำ HBM เครือข่ายและระบบเก็บข้อมูล ต้องให้ผลลัพธ์เร็วพอและมีต้นทุนต่อหนึ่งงานที่รับได้

6. การผลิตและพลังงาน: โรงงานชิป บรรจุภัณฑ์ ขั้นสูง อุปกรณ์ไฟฟ้า การเชื่อมต่อโครงข่าย การ ระบายความร้อน และเงินทุนสำหรับสร้างดาต้า เซ็นเตอร์

ข้อวิเคราะห์: มูลค่าไม่ได้จำเป็นต้องตกกับขั้นที่ใช้เงินลงทุนมากที่สุดเสมอไป แอปอาจเก็บรายได้จากลูกค้า แต่พึ่งต้นทุนคลาวด์; คลาวด์อาจมีงานมากขึ้นแต่ต้องลงทุนและแข่งขันด้านราคามากขึ้น; ผู้ขายชิปอาจมียอดขายสูง แต่การออกแบบ ASIC เองของคลาวด์เพิ่มทางเลือกของลูกค้า [Google: TPU สำหรับ inference](#) · [AWS: รองรับหลายโมเดล](#)

4. ทำไม Agent อาจใช้โครงสร้างพื้นฐานมากขึ้น

หนึ่งคำสั่งของผู้ใช้อาจกลายเป็นการค้นข้อมูล เรียกโมเดลหลายรอบ เขียนและรันโค้ด ตรวจสอบคำตอบ และให้ Agent ย่อยทำงานคู่ขนาน ข้อมูล Claude ที่ Anthropic ศึกษาพบว่า output ที่มอบอิสระให้ระบบ

ตัดสินใจมากขึ้นสัมพันธ์กับการใช้ token มากขึ้น แต่เป็นความสัมพันธ์ในข้อมูลของตน ไม่ใช่สมการสากลของ Agent ทุกตัว [Anthropic Economic Index](#)

IEA ระบุว่างานแบบ reasoning และ agentic อาจใช้พลังงานต่อคำขอมากกว่าข้อความสั้นธรรมดาหลายร้อยหรือหลายพันเท่าในบางรูปแบบ ขณะเดียวกันพลังงาน **ต่อหนึ่งงาน AI** ก็ลดลงอย่างรวดเร็วจากความก้าวหน้าของฮาร์ดแวร์และซอฟต์แวร์ ผลรวมจึงขึ้นกับจำนวนงาน ประเภทงาน และประสิทธิภาพ ไม่ใช่จำนวนบิตอย่างเดียว [IEA 2026](#)

แนวคิดที่ใช้ติดตามคือ:

ปริมาณประมวลผลโดยประมาณ = จำนวนงานจริง
× จำนวนรอบ/งาน × ปริมาณคำนวณ/รอบ - ผล
ของการทำให้แต่ละรอบมีประสิทธิภาพขึ้น

นี่เป็น **กรอบวิเคราะห์** ไม่ใช่ตัวเลขคาดการณ์ที่คำนวณแล้ว อีกด้านหนึ่งต้องวัด **งานที่สำเร็จและตรวจสอบได้ต่อหนึ่งดอลลาร์** เพราะจำนวน token มากขึ้นอาจหมายถึงงานมีคุณค่ามากขึ้น หรือ Agent วนซ้ำผิดพลาดก็ได้ [OpenAI: ประเมินผลตามงาน](#)

5. โครงสร้างพื้นฐานได้รับแรงกดดันตรงไหน

- **ชิปและหน่วยความจำ:** IEA ระบุว่า HBM เป็นข้อจำกัดของห่วงโซ่ชิป AI และคาดว่าความตึงตัวจะอยู่ถึงอย่างน้อยปลายปี 2027 นี่คือการประเมินตลาดรวม ไม่ใช่ผลของ Agent อย่างเดียว [IEA 2026](#)
- **เครือข่ายและระบบเซิร์ฟโมเดล:** งานที่ต้องตอบเร็วหรือประสานหลายเครื่องทำให้ bandwidth และ latency สำคัญ Google ระบุว่า TPU 8i ปรับหน่วยความจำและการเชื่อมต่อเพื่อ inference; ตัวเลขประสิทธิภาพ 80% ต่อดอลลาร์ที่ดีกว่ารุ่นก่อนเป็น [คำกล่าวของผู้ขาย Google, 22 เม.ย. 2026](#)
- **ไฟฟ้าและอุปกรณ์ดาต้าเซ็นเตอร์:** IEA ประเมินการใช้ไฟของดาต้าเซ็นเตอร์ทั่วโลกจาก 485 TWh ในปี 2025 เป็น 950 TWh ในปี 2030 ในกรณีกลาง และชี้ข้อจำกัดด้านสายส่ง หม้อแปลง และอุปกรณ์ไฟฟ้า ตัวเลขนี้รวมดาต้าเซ็นเตอร์หลายประเภท จึง **ห้ามอ้างว่าเป็นพลังงานของ Agent โดยเฉพาะ** [IEA 2026](#)

- **เงินทุน:** การสร้างกำลังผลิตล่วงหน้าต้องใช้เงินมาก IEA ระบุว่าค่าใช้จ่ายลงทุนของบริษัทเทคโนโลยีรายใหญ่เกิน 400 พันล้านดอลลาร์ในปี 2025 และประเมินว่าจะเพิ่มอีก 75% ในปี 2026 แต่การลงทุนไม่เท่ากับผลตอบแทนที่เกิดขึ้นแล้ว [IEA 2026](#)

6. ข้อเท็จจริงที่ต้องอ่านคู่กับข้อจำกัด

NVIDIA รายงานรายได้ Data Center ไตรมาส 2 ปีงบประมาณ 2027 ที่ 89.0 พันล้านดอลลาร์ เพิ่ม 117% จากปีก่อน ตัวเลขนี้สะท้อนตลาด AI infrastructure ที่ขยายตัว แต่ **แยกยอดขายที่เกิดจาก Agent ไม่ได้** และไม่ใช่ว่าหลักฐานว่าผู้ซื้อชิปได้ผลตอบแทนแล้ว [NVIDIA, 26 ส.ค. 2026](#)

ด้านการใช้งานจริง Anthropic พบ session ที่ทำงานยาวนานและใช้ Agent มากขึ้น แต่การศึกษาครอบคลุมเฉพาะ Claude ขณะที่การประเมิน Agent ในงานซอฟต์แวร์ของ METR แสดงความสามารถที่เพิ่มขึ้น พร้อมข้อจำกัดของ benchmark จึงยังไม่ควรย้ายผลไปสรุปทุกอุตสาหกรรม [Anthropic](#) · [METR](#)

7. คำถามที่ต้องตอบต่อในชุดวิเคราะห์

1. จำนวน งานที่สำเร็จจริง โตเร็วกว่าการลดต้นทุนต่อหนึ่งงานหรือไม่?
2. ใครถือความสัมพันธ์กับลูกค้า ข้อมูล และสิทธิในการลงมือทำ: แอป โมเดล หรือคลาวด์?
3. การใช้ชิปเพิ่มเป็น inference ใหม่จริง หรือเป็นการย้ายงานจากระบบเดิมและเพิ่มประสิทธิภาพ?
4. คอขวด HBM ไฟฟ้า และเงินทุนทำให้ผู้ขายบางรายมีอำนาจต่อรองหรือทำให้โครงการล่าช้า?
5. มีหลักฐานกำไรหรือผลผลิตสุทธิของลูกค้าหลังรวมค่าตรวจแก้ ความผิดพลาด และความเสียหายหรือไม่?

ชุดถัดไป [02_RESEARCH_AND_ANALYSIS.md](#) เปิดวิธีตรวจหลักฐาน สมมติฐานที่แข่งขันกัน และฉากทัศน์โดยยังไม่เลือกคำตอบสุดท้าย