

Agent Bot × AI Supply Chain: หลักฐาน กลไก และทางแยก

ชุดอ่าน 02 — วิจัยและวิเคราะห์เชิงลึก

โจทย์: การแข่งขัน Agent เปลี่ยนตำแหน่งการเก็บมูลค่าใน AI อย่างไร และส่งผ่านไปยังชิป คลาวด์ ดาต้าเซ็นเตอร์ เครือข่าย และพลังงานเพียงใด

ตรวจหลักฐานถึง: 29 กันยายน 2026

สถานะ: เจ้าของงานเลือก thesis แล้ว (29 กันยายน 2026); ยังไม่มีข้อสรุปเรื่องผู้ชนะหรือคำแนะนำลงทุน

Thesis ที่เจ้าของงานเลือก

แกนหลัก — “ปริมาณงาน Agent ที่สำเร็จจะโตเร็วพอชดเชยต้นทุนต่อหนึ่งงานที่ลดลงหรือไม่?”

การใช้ Agent เพิ่มความต้องการการประมวลผลเมื่อจำนวนงานที่สำเร็จและจำนวนรอบต่อหนึ่งงานโตเร็วกว่าประสิทธิภาพของโมเดล ชิป และระบบเสิร์ฟที่ดีขึ้น ความต้องการนี้ส่งต่อไปยังหน่วยความจำ เครือข่าย คลาวด์ ดาต้าเซ็นเตอร์และไฟฟ้า แต่ไม่ควรนับยอดขายฮาร์ดแวร์หรือการใช้ไฟทั้งหมดเป็นผลจาก Agent

มุมมอง — “ใครครองทางเข้างาน?” แอป ระบบข้อมูล สิทธิการเข้าถึง แพลตฟอร์ม Agent และคลาวด์มีอำนาจกำหนดว่างานถูกส่งให้โมเดลใดและใครรับส่วนต่าง จึงต้องแยก “อุปสงค์รวมที่โต” ออกจาก “ผู้ที่เก็บมูลค่าได้”

ข้อแย้งวิเคราะห์: ยังไม่มีหลักฐานพอจะฟันธงว่าการเติบโตของ Agent จะชนะการลดต้นทุนต่อ task หรือว่าขั้นใดจะได้กำไรสูงสุดในทุกกรณี เรื่องเล่าจะพาผู้ชมตามงานหนึ่งขึ้นจากผลลัพธ์ที่ตรวจได้ผ่าน compute ไปถึงคอขวดทางกายภาพ แล้วกลับมาที่ผู้ถือสิทธิ์และทางเข้างาน ก่อนจะจบด้วยตัวชี้วัดที่ต้องติดตาม แกนนี้เป็นคำถามแบบมีเงื่อนไข ไม่ใช่การคาดการณ์ราคาหุ้น

วิธีอ่านและวิธีตรวจ

ป้าย **[ข้อเท็จจริง]** หมายถึงข้อมูลที่แหล่งต้นทางบันทึกไว้; **[คำกล่าวผู้ขาย]** คือข้อมูลที่บริษัทเผยแพร่เกี่ยวกับตน ซึ่งตรวจขอบเขตและแรงจูงใจด้วย; **[วิเคราะห์]** คือเหตุผลที่อนุมานจากหลักฐาน; **[จากทัศน์]** คือสิ่งที่อาจเกิดขึ้นภายใต้เงื่อนไข ไม่ใช่คำพยากรณ์

ใช้เอกสารผลิตภัณฑ์ของ OpenAI, Anthropic, Google, AWS, Microsoft และ SpaceXAI เพื่อตรวจสอบสิ่งที่เปิดตัว; ใช้ข้อมูลผู้ใช้งานของ Anthropic และงานประเมินอิสระของ METR เพื่อตรวจสอบรูปแบบการใช้กับขีดจำกัด; ใช้ IEA, ผลประกอบการ NVIDIA และเอกสารเทคโนโลยี Google/TSMC เพื่อตรวจสอบโครงสร้างพื้นฐาน แหล่งเหล่านี้ตอบคนละคำถามจึงไม่เอาตัวเลขต่างชนิดมาเปรียบเทียบเป็นแท่งเดียวกัน

ตัวเลขยอดขายชิปหรือไฟฟ้าของดาต้าเซ็นเตอร์ ไม่สามารถระบุผลเชิงสาเหตุจาก Agent โดยเฉพาะ เพราะยังรวมการฝึกโมเดล, chatbot, วิดีโอ, search และงาน AI อื่น ๆ งานวิจัยใช้ช่วงเวลาและตัวอย่างต่างกัน อ่านวันที่เผยแพร่และช่วงเวลาวัดแยกกันเสมอ

1. ลำดับเหตุการณ์ที่เกี่ยวข้อง

- **2025:** OpenAI เปิด Responses API, เครื่องมือ computer use และ Agents SDK ให้ผู้พัฒนาประกอบ Agent; สิ่งนี้เป็นโครงสร้างพื้นฐานสำหรับ Agent ไม่ใช่หลักฐาน ROI ของลูกค้าทุกประเภท [OpenAI, 11 มี.ค. 2025](#)

- **ม.ค.–เม.ย. 2026:** Anthropic ขยายผลิตภัณฑ์ Claude Code/Cowork; Google ประกาศ TPU 8i สำหรับ inference และ AWS เพิ่ม managed harness ให้ AgentCore; Microsoft ประกาศ Agent 365 เป็นขั้นกำกับดูแล [Anthropic, 13 ม.ค.](#) · [Google, 22 เม.ย.](#) · [AWS, 22 เม.ย.](#) · [Microsoft, 9 มี.ค.](#)
- **พ.ค.–ก.ย. 2026:** Google เปิด Managed Agents; SpaceXAI เปิด Grok Bot beta; OpenAI เปิด Agents API public beta การเปิดตัวไม่เท่ากับส่วนแบ่งตลาดหรือการใช้งานเชิงพาณิชย์ในระดับเดียวกัน [Google, 19 พ.ค.](#) · [SpaceXAI, 11 ส.ค.](#) · [OpenAI, 10 ก.ย.](#)
- **2026:** IEA อัปเดตมุมมองพลังงานและข้อจำกัดในการขยายดาต้าเซ็นเตอร์ โดยให้กรณีกกลางถึงปี 2030 ไม่ใช่การทำงานเฉพาะ Agent [IEA](#)

2. กลไกเศรษฐศาสตร์: จากงานของคนไปสู่การใช้เครื่อง

อุปสงค์ที่ต้องแยกเป็นสี่ตัวแปร

[วิเคราะห์] งาน Agent 1 งานอาจเรียกโมเดลหลายรอบและใช้ sandbox/เครื่องมือ แต่จำนวนงานที่ทำจริงก็ขึ้นกับราคา คุณภาพ ความเชื่อใจ และสิทธิ์เข้าถึงระบบ ตัวแปรหลักคือ:

งานที่ต้องใช้ compute = จำนวนผู้ใช้ × งานที่มอบหมายต่อคน × รอบการทำงานต่อหนึ่งงาน × compute ต่อรอบ

จากนั้นหักผลของ model routing, โมเดลเล็ก, caching, batching, ชิปใหม่ และซอฟต์แวร์เสริม โมเดลที่ทำให้แต่ละรอบถูกลง สมการนี้เป็นแผนที่สาเหตุ ไม่ใช่สูตรประมาณยอดขายอย่างแม่นยำ

[Google: โครงสร้างชิป inference](#) · [OpenAI: ต้นทุนต่อผลลัพธ์](#)

Anthropic พบว่า output ที่มีระดับการมอบอิสระสูงมีการใช้ token มากขึ้น (สหสัมพันธ์ $r = 0.68$ ในชุด chat/Cowork) และ Claude Code มีระดับ autonomy มากกว่า chat/Cowork แม้เทียบโมเดล

เดียวกัน นี่เป็นความสัมพันธ์ภายในผลิตภัณฑ์
ไม่ใช่เหตุและผลทั่วตลาด อีกทั้งนับ token ไม่รวม
ต้นทุนคนตรวจหรือมูลค่าของงานที่เสร็จ [Anthropic](#),
[26 มิ.ย. 2026](#)

IEA บอกสองด้านพร้อมกัน: พลังงานต่อหนึ่งงานลดลง
อย่างน้อยระดับสิบเท่าต่อปีในช่วงหลังจากความ
ก้าวหน้าด้านเทคโนโลยี ขณะทำงาน
reasoning/agentive บางชนิดกินพลังงานต่อคำขอ
มากกว่าข้อความง่ายหลายร้อยถึงหลายพันเท่า ข้อ
สรุปจึงขึ้นกับ ปริมาณใช้ × ชนิดงาน ×
ประสิทธิภาพ ไม่ใช่การเลือกอ้างเพียงด้านที่
สนับสนุนมุมมองตน [IEA 2026](#)

ใครมีโอกาสเก็บส่วนต่าง

[วิเคราะห์] ผู้ครองช่องทางที่ผู้ใช้สั่งงานและระบบที่
Agent ต้องเข้า อาจกำหนดราคา เก็บบริบท และ
เลือกโมเดลเบื้องหลังได้ จึงมีอำนาจต่อรองต่อผู้ขาย
โมเดล แต่สิ่งนี้ขึ้นกับการย้ายข้อมูล ความเชื่อใจ และ
ความสามารถจริง Microsoft เน้น governance และ
ข้อมูลในงาน; AWS เน้น runtime/identity ที่ไม่ผูก
โมเดล; OpenAI กับ Anthropic ลงทุนทั้งโมเดลและ
harness [Microsoft](#) · [AWS](#) · [OpenAI](#) · [Anthropic](#)

อีกด้าน [วิเคราะห์] โมเดลที่เก่งกว่ามากอาจยังเก็บค่าเช่าทางเศรษฐกิจได้หากความผิดพลาดในงานแพ่งหรือโมเดลทดแทนทำงานไม่ได้ ส่วนแอปที่เป็นเพียงหน้าต่างเรียกโมเดลโดยไม่มีข้อมูล เครื่องมือ และการตรวจผล อาจถูกทำซ้ำง่าย ค่าเหล่านี้เป็นสมมติฐานการแข่งขัน ไม่ใช่การวัด margin ของบริษัทใด

อุปสงค์กับผลทดแทนเป็นคนละเรื่อง

OpenAI ระบุว่าควรวัดงานที่เสร็จ คุณภาพ และผลลัพธ์ต่อค่าใช้จ่าย มากกว่านับ token อย่างเดียว [OpenAI, 14 ก.ค. 2026](#) งานทดลองแบบสุ่มของ METR กับนักพัฒนา open-source ที่มีประสบการณ์ 16 คนและ 246 งาน (ช่วง ก.พ.-มิ.ย. 2025) พบการใช้เครื่องมือ AI ทำให้งานในเจ็อนไขทดลองช้าลงประมาณ 20%; METR เตือนว่าการทดลองใหม่ในปี 2026 มีอคติจากผู้ที่ไม่อยากทำงานโดยไม่มี AI จึงยังประมาณผลปัจจุบันอย่างน่าเชื่อถือไม่ได้ ห้ามแปลว่า **Agent** ทุกตัวทำให้คนช้าลง และห้ามใช้การยอมรับเทคโนโลยีแทนผลผลิตสุทธิ [METR, 24 ก.พ. 2026](#) · [งานวิจัยเดิม](#)

3. ผลต่อแต่ละชั้นของ Supply Chain AI

แอป ข้อมูล และการกำกับสิทธิ์

แรงบวก: ถ้า Agent เปลี่ยนจากถามตอบเป็นทำงานในระบบจริง แอปที่มีข้อมูลและ workflow อาจเก็บค่าบริการจากผลลัพธ์หรือการใช้งานซ้ำ ข้อมูลและสิทธิ์กลายเป็นจุดคอขวดเชิงธุรกิจ [Anthropic: สิ่งประกอบ](#) · [Microsoft: Agent 365](#)

แรงต้าน: ความผิดพลาด การรั่วไหลของข้อมูล และ prompt injection ทำให้องค์กรต้องซื้อการตรวจสอบและกำหนดขอบเขตการกระทำ มากกว่าปล่อยให้ Agent อิสระทั้งหมด การเชื่อมกับ ERP/CRM ที่มีสิทธิ์จริง อาจช้ากว่าการสาธิต [Anthropic: ความเสี่ยงและสิทธิ์](#)

โมเดลและแพลตฟอร์ม Agent

แรงบวก: งานหลายชั้นใช้โมเดล การเรียกเครื่องมือ หน่วยความจำ และการติดตามผล ผู้ให้บริการแพลตฟอร์มจึงขายมากกว่า token ได้หรือเพิ่มการใช้บริการเดิม OpenAI Agents API ยังคิดตาม token/เครื่องมือและ sandbox ไม่คิดค่า API เพิ่ม; AWS

ขายชั้น Runtime/Gateway/Identity/Evaluations;
Google มี managed sandbox [OpenAI](#) · [AWS](#) ·
[Google](#)

แรงดัน: แพลตฟอร์มรองรับหลายโมเดลทำให้
ลูกค้าสลับผู้ขายได้ง่ายขึ้น และการแข่งขันด้านราคา/
ประสิทธิภาพอาจทำให้มูลค่าต่อ token ลด แม้งาน
รวมเพิ่ม [AWS: model-agnostic](#) · [OpenAI: ราคา](#)
[และประสิทธิภาพ](#)

ชิป HBM และการผลิต

แรงบวก: หากจำนวนงาน agentic โตเร็วกว่า
ประสิทธิภาพที่ดีขึ้น จะต้องใช้กำลัง inference เพิ่ม
และมีความต้องการ HBM, packaging, CPU และ
เครือข่ายร่วมกับ accelerator NVIDIA รายงานรายได้
Data Center Q2 FY2027 ที่ 89.0 พันล้านดอลลาร์
เพิ่ม 117% ปีต่อปี [NVIDIA, 26 ส.ค. 2026](#)

ข้อจำกัด: รายได้นั้นรวมงาน AI อื่นและเป็นยอดขาย
ของผู้ขาย ไม่ใช่ ROI ของผู้ซื้อหรือยอดขายจาก
Agent โดยตรง IEA ระบุข้อจำกัด HBM ถึงอย่างน้อย
ปลาย 2027 และข้อจำกัดการผลิตชิปขั้นสูง; TSMC
ประกาศขยาย CoWoS เพื่อรองรับการรวมชิปและ

HBM มากขึ้น แต่แผนกำลังผลิตไม่เท่ากับส่งมอบและ
ทำกำไรแล้ว [IEA](#) · [TSMC 2026 Technology Symposium](#)

แรงแข่งขัน: Google ระบุว่า TPU 8i ให้
performance per dollar สำหรับ inference ดีกว่ารุ่น
ก่อน 80% ตัวเลขเป็นการเทียบผลิตภัณฑ์ของ
Google เอง ไม่ใช่ benchmark อีสระเทียบ NVIDIA
แต่แสดงว่าผู้ซื้อรายใหญ่มีทางเลือกออกแบบ ASIC
และปรับทั้ง stack [Google, 22 เม.ย. 2026](#)

คลาวด์ เครือข่าย ดาต้าเซ็นเตอร์ ไฟฟ้า

แรงบวก: Agent ที่รันยาวและตอบเร็วทำให้บริการ
runtime, sandbox, network และ storage เป็นส่วน
ของผลิตภัณฑ์ IEA ประเมินการใช้ไฟดาต้าเซ็นเตอร์
โลกกรณีกลาง 485 TWh (2025) → 950 TWh
(2030) ขณะที่ดาต้าเซ็นเตอร์เน้น AI โตเร็วกว่าค่า
เฉลี่ย [IEA 2026](#)

ข้อจำกัด: การเชื่อมไฟฟ้า หม้อแปลง อุปกรณ์กำลัง
ความหนาแน่นพลังงานต่อ rack ความเห็นชุมชนและ
เงินทุน ทำให้โครงการที่ประกาศไม่จำเป็นต้องสร้าง
เสร็จ IEA ระบุว่าการลงทุนดาต้าเซ็นเตอร์อ่อนไหวต่อ
ความเชื่อมั่นเรื่องผลตอบแทน; การใช้เงินทุนของ

บริษัทเทคโนโลยีใหญ่เกิน 400 พันล้านดอลลาร์ในปี 2025 และคาดว่าจะเพิ่ม 75% ในปี 2026 เป็นขนาดการลงทุน ไม่ใช่กำไรจาก Agent [IEA 2026](#)

4. สมมติฐานที่แข่งขันกัน

A — ปริมาณงานชนะประสิทธิภาพ [จากทัศน์].

Agent ได้งานเข้าจำนวนมากและงานยาวที่มีคุณค่า จึงเพิ่ม inference รวมเร็วกว่า cost/task ที่ลด ผู้ขายกำลังประมวลผล HBM เครือข่าย และไฟฟ้าได้รับอุปสงค์ต่อเนื่อง ข้อมูลที่หนุน: การใช้ Agent ยาวขึ้นในระบบ Anthropic และการลงทุน/รายได้โครงสร้างพื้นฐานที่เพิ่ม ข้อมูลที่ยังขาด: สัดส่วนของ Agent ใน workload รวม และกำไรต่อหนึ่งงาน [Anthropic · NVIDIA](#)

B — ประสิทธิภาพและการแข่งขันชนะ [จาก

ทัศน์]. ความสามารถต่อดอลลาร์ดีขึ้น, งานง่ายย้ายไปโมเดลเล็ก/ASIC, ระบบใช้ cache และ routing ทำให้ Agent เพิ่มจำนวนแต่ไม่เพิ่ม compute หรือรายได้ฮาร์ดแวร์ตามสัดส่วน ข้อมูลที่หนุน: IEA ระบุพลังงานต่อ task ลดมาก, Google เสนอชิป

inference เฉพาะ, OpenAI ระบายราคา token ลด
ข้อมูลที่ยังขาด: elasticity จริงของอุปสงค์เมื่อราคา
ลด [IEA](#) · [Google](#) · [OpenAI](#)

C — งานมีจริงแต่ขยายช้า [จากทัศน์]. การพิสูจน์
ROI, สิทธิข้อมูล, การตรวจผิดพลาด และข้อจำกัด
ไฟฟ้า/HBM ทำให้การลงทุนเร็วกว่าการใช้งานที่จ่าย
คัมในระยะต้น ข้อมูลที่หนึ่: METR พบผลผลิตไม่ได้
บวกเสมอในงานหนึ่งและ IEA ระบุคอขวด ข้อมูลที่ยัง
ขาด: ตัวอย่างองค์กรจำนวนมากที่วัดผลสุทธิหลังใช้
Agent จริง [METR](#) · [IEA](#)

สามจากทัศน์อาจเกิดต่างกันตามช่วงเวลาและ
ประเภทงาน ไม่ใช่ตัวเลือกที่ต้องมีเพียงหนึ่งเดียว

5. หลักฐานค้านและจุดที่ห้ามกล่าวเกิน

1. **เปิดตัว ≠ ใช้จริงในวงกว้าง.** ข่าวผลิตภัณฑ์บอก
ความสามารถที่เสนอและความตั้งใจของผู้ขาย ไม่
บอกจำนวนงานที่สำเร็จสุทธิหรือการต่อสัญญาของ
ลูกค้า

2. **token มาก $\neq$ มูลค่าสูง.** งานที่ซับซ้อนอาจใช้ token มากและมีคุณค่า แต่การวนซ้ำผิดพลาดก็ใช้ token มาก ต้องวัด completion, quality, review time และ spend ต่อ task [OpenAI](#)
3. **ไฟฟ้าดาต้าเซ็นเตอร์ $\neq$ ไฟฟ้า Agent.** ตัวเลข IEA รวมหลาย workload และเป็นกรณีคาดการณ์ถึง 2030 ไม่มีตัวคูณที่นำจำนวน Agent ไปแปลงเป็น TWh ได้ตรง ๆ [IEA](#)
4. **ยอดขาย GPU $\neq$ ลูกค้าได้กำไร.** รายได้ NVIDIA ยืนยันยอดขายช่วงหนึ่ง ไม่ยืนยัน utilization ระยะยาวหรือความสามารถจ่ายของแอปปลายทาง [NVIDIA](#)
5. **benchmark $\neq$ ผลธุรกิจทุกประเภท.** METR time horizon วัดงานซอฟต์แวร์ชุดหนึ่งที่ Agent ทำสำเร็จด้วยความน่าจะเป็นระดับหนึ่ง ไม่ใช่เวลาที่ระบบทำงานเองจริงหรือผลตอบแทนทางการเงิน [METR](#)
6. **ผู้ขายชิปเดิม $\neq$ ชนะทุกแบบของ inference.** การออกแบบ ASIC และการเพิ่มประสิทธิภาพบริการ inference เพิ่มการแข่งขัน แต่ยังไม่พิสูจน์ว่าชิปใดแทนกันได้สมบูรณ์ในทุก workload [Google](#)

6. สิ่งที่ต้องติดตามเพื่อตัดสินใจตัดสินใจ

- **ปลายทาง:** งานที่ Agent จบและตรวจได้ต่อเดือน, อัตราต้องแก้, เวลาคนตรวจ, อัตราต่อสัญญา, รายได้สุทธิต่อ task
- **โมเดล/คลาวด์:** token และ tool calls ต่อ task ที่สำเร็จ, ต้นทุนรวมต่อ task, สัดส่วน routing ไปโมเดลเล็ก, utilization, margin หลังหักพลังงานและค่าเสื่อม
- **ชิป/ซัพพลาย:** HBM และ packaging capacity ที่ส่งมอบจริง, lead time, การใช้ GPU/ASIC, ค่าสั่งซื้อที่ยืนยันเทียบกับแผน
- **ดาต้าเซ็นเตอร์:** เมกะวัตต์ที่ต่อไฟแล้ว, ระยะเวลารอเชื่อมกริด, ต้นทุนไฟและระบายความร้อน, โครงการที่เลื่อน/ยกเลิก

หากข้อมูลเหล่านี้ไม่เปิดเผย ควรกล่าวว่า **ยังวัดไม่ได้**
ไม่เติมตัวเลขสมมติให้ดูแน่นอน

7. Claim ledger สำหรับตรวจย้อนหลัง

C01 — บริษัทชั้นนำเปิด Agent หลายแบบ

ประเภท: [ข้อเท็จจริงเรื่องการเปิดตัว]

แหล่ง: [OpenAI 10 ก.ย. 2026](#), [Google 19 พ.ค. 2026](#), [AWS 22 เม.ย. 2026](#), [Microsoft 9 มี.ค. 2026](#), [SpaceXAI 11 ส.ค. 2026](#)

ข้อจำกัด/คำอธิบายอื่น: ผลิตภัณฑ์ต่างหน้าที่และระดับความพร้อม; ขาวเปิดตัวไม่วัดการใช้จริง

ความมั่นใจ: สูงเฉพาะการเปิดตัว; ต่ำต่อข้ออ้างว่าผลตอบแทนกว้างขวาง

ผลต่อการเล่า: แสดงหลายทางเข้าสู่งานเดียวกัน ไม่วาดว่าเหมือนกันทั้งหมด

C02 — การมอบอิสระสัมพันธ์กับ token ที่ใช้มากขึ้น

ประเภท: [ข้อเท็จจริงในข้อมูลผู้ให้บริการ]

แหล่ง: [Anthropic Economic Index](#), เผยแพร่ 26 มิ.ย. 2026; ข้อมูลผลิตภัณฑ์ของตนในช่วง เม.ย.–มิ.ย. 2026

หลักฐาน: ความสัมพันธ์ $r = 0.68$ ระหว่างระดับ autonomy เชลี่ยกับ median token ในกลุ่ม artifact บน chat/Cowork

ข้อจำกัด: เป็นความสัมพันธ์ ไม่ใช่เหตุผลเชิงสาเหตุ;
ข้อมูล Claude ไม่แทนทั้งตลาด
ความมั่นใจ: กลางต่อทิศทางในตัวอย่าง; ต่ำต่อ
ขนาดผลรวมอุตสาหกรรม
ผลต่อการเล่า: ภาพงานยาวอาจใช้หลายรอบ แต่
ห้ามใส่สเกล GPU แบบวัดจริง

C03 — Agent บางงานใช้พลังงานมาก แต่ ประสิทธิภาพต่อ task ก็ดีขึ้น

ประเภท: [การประเมินของหน่วยงานอิสระ]
แหล่ง: [IEA, Key Questions on Energy and AI, 2026](#)

หลักฐาน: งาน reasoning/agentive บางชนิดใช้
พลังงานต่อคำขอมากกว่าข้อความง่ายหลายร้อย/พัน
เท่า; พลังงานต่อ task ลดลงอย่างน้อยหนึ่ง order of
magnitude ต่อปีในช่วงหลัง

ข้อจำกัด: ช่วงการใช้พลังงานขึ้นกับชนิดงาน;
disclosure ยังไม่ครบ; ไม่มีค่าเฉลี่ย Agent หนึ่งตัวที่
ใช้ได้ทั่วไป

ความมั่นใจ: กลางต่อกลไก; ต่ำต่อการทำนาย
Agent-only load

ผลต่อการเล่า: ให้สองแรงสวนกันอยู่ในภาพเดียว

C04 — ไฟฟ้าดาต้าเซ็นเตอร์อาจเกือบเท่าตัวถึงปี 2030

ประเภท: [ประมาณการกรณีกลาง]

แหล่ง: [IEA 2026](#)

หลักฐาน: 485 TWh ในปี 2025 เทียบกับ 950 TWh ในปี 2030

ข้อจำกัด: รวมดาต้าเซ็นเตอร์ทั้งหมด; ขึ้นกับเงินทุนการต่อไฟ และการใช้ AI; ไม่ใช่ไฟฟ้าจาก Agent เท่านั้น

ความมั่นใจ: กลางต่อการเป็นกรณีกลางของ IEA; ต่ำต่อผลลัพธ์จริงปี 2030

ผลต่อการเล่า: หากใช้กราฟต้องติดป้าย “global data centres, IEA central case”

C05 — HBM และอุปกรณ์ไฟฟ้าเป็นข้อจำกัด

ประเภท: [การประเมินห่วงโซ่อุปทาน]

แหล่ง: [IEA 2026](#), [TSMC 2026 Technology Symposium](#)

หลักฐาน: IEA คาดความตึงตัว HBM อย่างน้อยถึงปลาย 2027 และชี้ข้อจำกัดหม้อแปลง/อุปกรณ์กำลัง; TSMC วางแผนขยาย CoWoS

ข้อจำกัด: สถานะอาจเปลี่ยนเมื่อกำลังผลิตมาเพิ่ม; ไม่มีสัดส่วนที่เกิดจาก Agent แยกต่างหาก

ความมั่นใจ: กลาง

ผลต่อการเล่า: แสดงการต่อกันของคอขวด ไม่ระบบ
บริษัทผู้ชนะจากแผนที่นี้

C06 — รายได้ Data Center ของ NVIDIA โตแรง

ประเภท: [ผลประกอบการบริษัท]

แหล่ง: [NVIDIA Q2 FY2027, ไตรมาสสิ้นสุด 26
ก.ค.; เผยแพร่ 26 ส.ค. 2026](#)

หลักฐาน: 89.0 พันล้านดอลลาร์ เพิ่ม 117% ปีต่อปี

ข้อจำกัด: รวมหลายงาน AI และธุรกิจ Data Center;

ไม่บอก ROI ของลูกค้าหรือส่วนที่ Agent สร้าง

ความมั่นใจ: สูงต่อยอดรายงาน; ต่ำต่อการแยก
Agent

ผลต่อการเล่า: ใช้เป็นภาพขนาดตลาดอุปกรณ์ ไม่
อ้างความสำเร็จของ Agent

C07 — ASIC และการทำ inference ให้ถูกลง เป็นแรงแข่งขัน

ประเภท: [คำกล่าวผู้ขาย + วิเคราะห์]

แหล่ง: [Google TPU 8i, 22 เม.ย. 2026](#)

หลักฐาน: Google ระบุ performance per dollar ดี
ขึ้น 80% จาก TPU รุ่นก่อนสำหรับ inference

ข้อจำกัด: เทียบผลิตภัณฑ์ตนเอง ไม่มีการยืนยันว่า
แทน GPU ทุกชนิดได้; อาจมีต้นทุนเปลี่ยนระบบ
ความมั่นใจ: กลางต่อความตั้งใจและทิศทาง
ออกแบบ; ต่ำต่อผลส่วนแบ่งตลาด
ผลต่อการเล่า: อย่างรวดเร็วชนิดหนึ่งขณะเด็ดขาด

C08 — งานที่ใช้ AI อาจไม่เพิ่มผลิตภาพ เสมอ

ประเภท: [งานทดลองที่มีขอบเขต]

แหล่ง: METR, ศึกษางาน ก.พ.-มิ.ย. 2025, อัปเดต
24 ก.พ. 2026

หลักฐาน: 16 นักพัฒนา, 246 งาน, ชำลงประมาณ
20% ภายใต้เงื่อนไขการทดลองเดิม; การทดลองใหม่
ให้สัญญาณที่ไม่น่าเชื่อถือเรื่องผลปัจจุบัน

ข้อจำกัด: งานและผู้เข้าร่วมเฉพาะกลุ่ม; เครื่องมือ
เปลี่ยนเร็ว; ไม่ใช่งาน Agent ทั้งหมด

ความมั่นใจ: กลางต่อผลการทดลองเดิม; ต่ำต่อ
การนำไปทำนายปี 2026

ผลต่อการเล่า: เตือนว่าการใช้จริงและผลสุทธิต่าง
กัน

C09 — การกำกับสิทธิ์เป็นส่วนของคุณค่าทางธุรกิจ

ประเภท: [ข้อเท็จจริงด้านผลิตภัณฑ์ + วิเคราะห์]

แหล่ง: [Microsoft Agent 365](#), [AWS AgentCore](#), [Anthropic ความปลอดภัย](#)

หลักฐาน: ผู้ขายสร้างชั้น identity, policy, observability และ evaluations

ข้อจำกัด: การมีผลิตภัณฑ์ไม่ยืนยันรายได้หรือ moat ที่ยั่งยืน

ความมั่นใจ: สูงต่อการมีชั้นผลิตภัณฑ์; กลางต่อความสำคัญเชิงกลยุทธ์

ผลต่อการเล่า: แสดง Agent ต้องผ่านประตูลิขสิทธิ์ก่อนลงมือ

C10 — การเปิดตัว Agent 'ไม่ยืนยัน ROI' ทั่วไป

ประเภท: [วิเคราะห์จากช่องว่างหลักฐาน]

แหล่ง: [OpenAI: วัดผลลัพธ์](#), [METR](#), [IEA: ความไวต่อผลตอบแทน](#)

ข้อโต้แย้งที่เป็นไปได้: บางองค์กรอาจได้ผลตอบแทนสูงในงานเฉพาะ แม้ยังไม่มีข้อมูลภาพรวม

ความมั่นใจ: สูงว่า “ยังพิสูจน์ทั่วไปไม่ได้”; ต่ำต่อ

การระบุผู้แพ้ชนะรายบริษัท

ผลต่อการเล่า: จบด้วยคำถามที่วัดได้ ไม่ใช่รายชื่อ
หุ่นชนะ

8. เหตุผลที่เลือก thesis นี้ และทางเลือกที่ไม่ใช่แกนหลัก

- **ทางเลือก ก:** ใครจะถือจุดรับงานและผลลัพธ์ เมื่อโมเดลกลายเป็นส่วนที่สลับได้?
- **ทางเลือก ข:** Agent จะเปลี่ยนจากการซื้อกำลังฝึกโมเดลไปเป็นการซื้อ inference และโครงสร้างพื้นฐานชนิดใด?
- **ทางเลือก ค:** การเติบโตของงาน Agent จะมากพอชนะการลดต้นทุนต่อ task และข้อจำกัดไฟฟ้า/HBM หรือไม่?

เจ้าของงานเลือก **ทางเลือก ค** เป็นแกนหลัก และใช้ **ทางเลือก ก** เป็นมุมเสริม ทางเลือก ข เป็นกลไกในช่วงกลางเรื่อง: งานที่ถูกมอบหมายมากขึ้นอาจทำให้ inference โต แต่รูปแบบการใช้เครื่องไม่ตายตัวเพราะ routing, caching, ASIC และต้นทุนพลังงานเปลี่ยน

ได้ การเลือกนี้ช่วยรักษาความไม่แน่นอนที่หลักฐานยังตอบไม่ได้ และทำให้ตอนจบเป็นเงื่อนไขที่วัดได้ แทนการประกาศผู้ชนะล่วงหน้า

สิ่งที่ต้องวัดต่อ: จำนวน task ที่ตรวจว่าเสร็จจริง, ต้นทุนรวมต่อ task (รวมการตรวจของคน), จำนวน model/tool calls ต่อ task, การใช้กำลัง inference, เวลารอและอัตราความผิดพลาด, การจัดสรรงานระหว่าง GPU/ASIC, และข้อจำกัด HBM/ไฟฟ้า ตัวแปรเหล่านี้ต้องอ่านร่วมกันและแยกข้อมูล AI ทั้งระบบออกจากส่วนที่ Agent ก่อโดยตรง

แหล่งหลักและวันที่

- [OpenAI, Agents API, 10 ก.ย. 2026; ต้นทุนและผลลัพธ์, 14 ก.ค. 2026](#)
- [Anthropic, Economic Index, 26 มิ.ย. 2026; การใช้ Agent จริง, 18 ก.พ. 2026; ความปลอดภัย, 9 เม.ย. 2026](#)
- [Google, Managed Agents, 19 พ.ค. 2026; TPU 8i, 22 เม.ย. 2026](#)

- [AWS, AgentCore, 22 เม.ย. 2026](#); [Microsoft, Agent 365, 9 มี.ค. 2026](#); [SpaceXAI, Grok Bot, 11 ส.ค. 2026](#)
- [IEA, Key Questions on Energy and AI, 2026](#); [NVIDIA, Q2 FY2027, 26 ส.ค. 2026](#); [TSMC, Technology Symposium 2026](#)
- [METR, randomized trial, ข้อมูล ก.พ.-มิ.ย. 2025](#); [METR, อัปเดต 24 ก.พ. 2026](#)